

PFB - cluster

October 6, 2025

```
[207]: import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
import numpy as np
```

```
[208]: data1 = pd.read_csv("data2_pfb2_b.csv")
```

```
[209]: data1.head(2)
```

```
[209]:
```


	sexo	positiva_alcohol	positiva_droga	franja_horaria	edades	\
0	Mujer	N	N	Mañana	De 19 a 59 años	
1	Hombre	N	N	Mañana	De 19 a 59 años	

	tipo_siniestro	tipo_vehiculo	tipo_asistencia	\
0	Colisiones_salidas_via	Vehiculos_ligeros	Sin asistencia sanitaria	
1	Colisiones_salidas_via	Vehiculos_ligeros	Sin asistencia sanitaria	

	zona_geografica	estado_clima
0	Noreste	Buen_tiempo
1	Noreste	Buen_tiempo

```
[210]: plt.figure(figsize=(4, 3))
sns.countplot(x = data1['zona_geografica'])
```

```
[210]: <Axes: xlabel='zona_geografica', ylabel='count'>
```



```
[211]: dummies = pd.get_dummies(data1, drop_first=True)*1
```

```
[212]: data_normalizada = (dummies - dummies.min()) / (dummies.max() - dummies.min())
data_normalizada.head(2)
```

```
[212]:
```

	sexo_Mujer	positiva_alcohol_S	positiva_droga_S	franja_horaria_Tarde \
0	1.0	0.0	0.0	0.0
1	0.0	0.0	0.0	0.0

	edades_Menores_mayores_60	tipo_siniestro_Colisiones_salidas_via \
0	0.0	1.0
1	0.0	1.0

	tipo_vehiculo_Vehiculos_pesados	tipo_asistencia_Sin asistencia sanitaria \
0	0.0	1.0
1	0.0	1.0

	zona_geografica_Suroeste	estado_clima_Mal_tiempo
0	0.0	0.0
1	0.0	0.0

```
[213]: from sklearn.cluster import KMeans
```

```
modelo = KMeans(
    n_clusters = 5,
    n_init = 10,
    max_iter = 300
)
```

```
modelo.fit(data_normalizada)
```

```
[213]: KMeans(n_clusters=5, n_init=10)
```

```
[214]: np.unique(modelo.labels_)
```

```
[214]: array([0, 1, 2, 3, 4])
```

```
[215]: modelo.inertia_
```

```
[215]: 21546.50622862781
```

```
[216]: acum = []  
for i in range(2,11):  
    modelo = KMeans(  
        n_clusters = i, # numero de centroides (o semillas en cada iteración)  
        n_init = 10, # cuantas veces distintas voy a tirar i puntos rojos  
        max_iter = 300 # cuantas veces itero por cada tirada de 5 semillas  
    )  
    modelo.fit(data_normalizada)  
    acum.append([i, modelo.inertia_])
```

```
[217]: acum
```


```
[217]: [[2, 29026.721941714783],  
       [3, 26662.067718350307],  
       [4, 23785.76853574877],  
       [5, 21561.943156424153],  
       [6, 20079.9071923987],  
       [7, 19074.556706573545],  
       [8, 17588.24818348567],  
       [9, 16777.309296992717],  
       [10, 16141.101853122433]]
```

```
[218]: np.array(acum)[: ,0]
```

```
[218]: array([ 2.,  3.,  4.,  5.,  6.,  7.,  8.,  9., 10.])
```

```
[219]: plt.figure(figsize=(4, 3))  
sns.lineplot(x = np.array(acum)[: ,0], y = np.array(acum)[: , 1])
```

```
[219]: <Axes: >
```



```
[220]: modelo = KMeans(
        n_clusters = 5,
        n_init = 10,
        max_iter = 300
    )
    modelo.fit(data_normalizada)
```

```
[220]: KMeans(n_clusters=5, n_init=10)
```

```
[221]: dummies["cluster"] = modelo.labels_
```

```
[222]: dummies.groupby("cluster").mean()
```

```
[222]:
```

	sexo_Mujer	positiva_alcohol_S	positiva_droga_S \
cluster			
0	0.212438	0.010793	0.004112
1	0.788281	0.014607	0.003358
2	0.129656	0.032056	0.009133
3	0.324005	0.026534	0.004768
4	0.000000	0.025349	0.007760

	franja_horaria_Tarde	edades_Menores_mayores_60 \
cluster		
0	0.000000	0.180744
1	0.702653	0.209033
2	0.384133	0.186246
3	1.000000	0.170398
4	1.000000	0.150543

cluster	tipo_siniestro_Colisiones_salidas_via \
0	0.858318
1	0.796172
2	0.820559
3	0.863391
4	0.878945

cluster	tipo_vehiculo_Vehiculos_pesados \
0	0.072983
1	0.058261
2	0.077722
3	0.062811
4	0.026384

cluster	tipo_asistencia_Sin asistencia sanitaria	zona_geografica_Suroeste \
0	0.697790	0.000000
1	0.150772	0.620551
2	0.812858	1.000000
3	1.000000	0.000000
4	0.000000	0.000000

cluster	estado_clima_Mal tiempo
0	0.150248
1	0.155306
2	0.147744
3	0.140547
4	0.160890

```
[223]: from sklearn.metrics import silhouette_score
silhouette_score(data_normalizada, modelo.labels_)
```

```
[223]: 0.18477777974715703
```

```
[ ]: #El modelo encontró patrones, pero los grupos no están muy definidos
      ↪(silhouette score: 0.18), lo que indica que las diferencias entre zonas no
      ↪son tan claras
```

```
[224]: plt.figure(figsize=(4, 4))
dummies['zona_suroeste_label'] = dummies['zona_geografica_Suroeste'].map({0:
      ↪'Fuera del Suroeste', 1: 'Dentro del Suroeste'})
sns.histplot(
    data=dummies,
    x='zona_suroeste_label',
```

```

    hue='cluster',
    multiple='stack',
    shrink=0.8,
    palette='Blues',
    discrete=True
)

plt.title('Distribución de clusters por zona geográfica Suroeste')
plt.xlabel('Zona geográfica')
plt.ylabel('Cantidad de registros')
plt.xticks(rotation=0)
plt.tight_layout()
plt.show()

```

Distribución de clusters por zona geográfica Suroeste

