



SINIESTRALIDAD EN LA COMUNIDAD DE MADRID / 2024

PROYECTO FIN DE BOOTCAMP NEOLAND SOBRE PROCESAMIENTO Y ANÁLISIS DE BASE DE DATOS


OCTUBRE DE 2025 POR PATRICIA BENITEZ

SUMARIO



Objetivos y metodología aplicada:

- Objetivo y proceso
- Base de datos
- ETL



Análisis y hallazgos:

- Descriptivo
- Predictivo



Resultados:

- Conclusiones
- Dashboard

OBJETIVO



El presente análisis se centró en el estudio de los **accidentes ocurridos en la Comunidad de Madrid en el año 2024** con el objetivo de responder preguntas clave sobre la frecuencia, localización y circunstancias asociadas a la lesividad de los accidentes.

Este proyecto permitió demostrar competencias en **análisis exploratorio, preparación de datos para modelos predictivos y generación de insights** útiles para la toma de decisiones en seguridad vial.

PROCESO

1. Extracción y exploración inicial

Se descargó la base de datos pública desde la web oficial, y se utilizó lenguaje de código para realizar una inspección preliminar: revisión del tamaño, estructura y contenido general. Se exploraron las columnas una a una para entender su significado, formato y relevancia para el análisis.

2. Limpieza y preparación de datos y visualización descriptiva

Se eliminaron columnas irrelevantes o redundantes, se trataron valores nulos y se ajustaron los tipos de datos para asegurar consistencia y trazabilidad. Esta fase incluyó la normalización de variables categóricas y la creación de nuevas variables derivadas para enriquecer el análisis. Posteriormente se realizó un dashboard descriptivo.

3. Análisis avanzado y modelado predictivo

Se aplicaron técnicas de Machine Learning para identificar correlaciones entre variables y detectar patrones significativos. El modelo se centró en predecir probabilidades como la posibilidad de que un accidente resulte con lesiones o el tipo de accidente más habitual.

BASE DE DATOS

¿De qué datos disponemos?, ¿de qué se compone nuestro dataset?

ORIGEN

web <https://datos.madrid.es/portal/site/egob>

FORMATO

.CSV



Archivo de
separados por comas

TAMAÑO

49,340 X 19

LENGUAJE ETL:

Phyton

LIBRERIAS

Pandas, Numpy, Seabron, matplotlib

VISUALIZACION

Power BI

	A	B	C	D	E	F	
1	num_expediente	fecha	hora	cod_distrito	distrito	tipo_accidente	estado
2	2024S000001	2024-01-01	01:20:00	3	RETIRO	ColisiÃ³n mÃltiple	Despejado
3	2024S000001	2024-01-01	01:20:00	3	RETIRO	ColisiÃ³n mÃltiple	Despejado
4	2024S000001	2024-01-01	01:20:00	3	RETIRO	ColisiÃ³n mÃltiple	Despejado
5	2024S000001	2024-01-01	01:20:00	3	RETIRO	ColisiÃ³n mÃltiple	Despejado
6	2024S000001	2024-01-01	01:20:00	3	RETIRO	ColisiÃ³n mÃltiple	Despejado
7	2024S000001	2024-01-01	01:20:00	3	RETIRO	ColisiÃ³n mÃltiple	Despejado
8	2024S000001	2024-01-01	01:20:00	3	RETIRO	ColisiÃ³n mÃltiple	Despejado
9	2024S000001	2024-01-01	01:20:00	3	RETIRO	ColisiÃ³n mÃltiple	Despejado
10	2024S000001	2024-01-01	01:20:00	3	RETIRO	ColisiÃ³n mÃltiple	Despejado
11	2024S000002	2024-01-01	02:45:00	13	PUENTE DE VALLECAS	Choque contra	
12	2024S000003	2024-01-01	03:42:00	13	PUENTE DE VALLECAS	Choque contra	
13	2024S000005	2024-01-01	05:42:00	13	PUENTE DE VALLECAS	Choque contra	
14	2024S000007	2024-01-01	07:30:00	3	RETIRO	ColisiÃ³n mÃltiple	Despejado
15	2024S000007	2024-01-01	07:30:00	3	RETIRO	ColisiÃ³n mÃltiple	Despejado

BASE DE DATOS

COLUMNAS:

- Número de expediente (año/S/número) OBJECT
- Fecha OBJECT
- Hora OBJECT
- Localización (calle o carretera) OBJECT
- Numero (de la calle o carretera) OBJECT
- Código de distrito INT
- Distrito (nombre) OBJECT
- Tipo de accidente (colisión, atropello, salida de vía...) OBJECT
- Estado meteorológico OBJECT
- Tipo de vehículo (turismo, sin motor, pesado...) OBJECT
- Tipo de persona (ocupante o peatón) OBJECT
- Rango de edad (por grupos de 5) OBJECT
- Sexo OBJECT
- Código de lesividad FLOAT
- Lesividad (si ha sido asistido, fallecido, sin asistencia...) OBJECT
- Coordenadas (dos columnas) FLOAT
- Positivo en alcohol OBJECT
- Positivo en drogas FLOAT

	A	B	C	D	E	F	
1	num_expediente	fecha	hora	cod_distrito	distrito	tipo_accidente	estado
2	2024S000001	2024-01-01	01:20:00	3	RETIRO	ColisiÃ³n mÃltiple	Despejado
3	2024S000001	2024-01-01	01:20:00	3	RETIRO	ColisiÃ³n mÃltiple	Despejado
4	2024S000001	2024-01-01	01:20:00	3	RETIRO	ColisiÃ³n mÃltiple	Despejado
5	2024S000001	2024-01-01	01:20:00	3	RETIRO	ColisiÃ³n mÃltiple	Despejado
6	2024S000001	2024-01-01	01:20:00	3	RETIRO	ColisiÃ³n mÃltiple	Despejado
7	2024S000001	2024-01-01	01:20:00	3	RETIRO	ColisiÃ³n mÃltiple	Despejado
8	2024S000001	2024-01-01	01:20:00	3	RETIRO	ColisiÃ³n mÃltiple	Despejado
9	2024S000001	2024-01-01	01:20:00	3	RETIRO	ColisiÃ³n mÃltiple	Despejado
10	2024S000001	2024-01-01	01:20:00	3	RETIRO	ColisiÃ³n mÃltiple	Despejado
11	2024S000002	2024-01-01	02:45:00	13	PUENTE DE VALLECAS	Choque contra	
12	2024S000003	2024-01-01	03:45:00	13	PUENTE DE VALLECAS	Choque contra	
13	2024S000005	2024-01-01	05:42:00	13	PUENTE DE VALLECAS	Choque contra	
14	2024S000007	2024-01-01	07:30:00	3	RETIRO	ColisiÃ³n mÃltiple	Despejado
15	2024S000008	2024-01-01	07:30:00	3	RETIRO	ColisiÃ³n mÃltiple	Despejado

ETL

1. REVISIÓN Y LIMPIEZA INICIAL

Se identificaron columnas con **valores nulos y formatos inconsistentes**.

Se eliminaron **columnas innecesarias**: localización, número, coordenadas (estas no eran precisas tras comprobaciones en google maps).

Se eliminaron 12 filas correspondientes a **expedientes del año 2023** por no ser relevantes para el análisis.

2. NORMALIZACIÓN DE FORMATOS

Se transformaron las columnas fecha y hora al **formato DATETIME**.

Se creó una nueva **columna de franja horaria** (mañana, tarde, noche) agrupando los tramos:

Mañana: 07:00–14:59, Tarde: 15:00–22:59, Noche: 23:00–06:59

3. CONVERSIÓN GEOGRÁFICA

Se creó una **columna de código postal** a partir de un diccionario que relaciona cada distrito con su código correspondiente.

ETL

4. TRATAMIENTO DE VALORES NULOS Y AGRUPACIONES

Se **eliminaron 5 filas** vacías en la columna tipo de accidente, correspondientes a 2 expedientes únicos. Posteriormente, se **agruparon los 12 tipos en 5 categorías** principales.

En la columna estado meteorológico, se imputaron **356 valores nulos utilizando la moda** en vista de la distribución de los datos.

En tipo de vehículo, se reemplazaron **394 valores nulos por “Se desconoce”** y se **agruparon 32 tipos en 7 categorías**.

La variable edad se redujo de **18 rangos a 5 grupos amplios**.

La columna lesividad se **agrupó en 4 niveles a partir de 10 categorías** originales. Los valores nulos se asignaron a **“Se desconoce”**.

5. AJUSTE DE TIPOS DE DATOS

La columna positiva en droga se transformó de tipo **INT a OBJECT**, con valores **“S” y “N”**, igualando el formato de positivo en alcohol.

6. VERIFICACIÓN FINAL

Se confirmó que **no quedan valores nulos** tras todas las transformaciones aplicadas.

SCRIPT




Adobe Acrobat
Document

ANÁLISIS Y HALLAZGOS


ANÁLISIS DESCRIPTIVO

TOP DISTRITOS CON MAS SINIESTRALIDAD

Distritos con más de 1.200 accidentes



Expedientes por distrito



PUENTE DE VALLECAS

1.530

Expedientes

40 %

Con asistencia sanitaria

CHAMARTIN

1.470

Expedientes

44 %

Con asistencia sanitaria

CARABANCHEL

1.440

Expedientes

42 %

Con asistencia sanitaria

SALAMANCA

1.393

Expedientes

47 %

Con asistencia sanitaria

CENTRO

1.325

Expedientes

45 %

Con asistencia sanitaria

CIUDAD LINEAL

1.245

Expedientes




45 %

Con asistencia sanitaria

ANALISIS Y HALLAZGOS

ANÁLISIS DESCRIPTIVO

SINIESTRALIDAD POR MESES / TIPOS DE SINIESTRO Y VEHICULO






ANÁLISIS Y HALLAZGOS

ANÁLISIS DESCRIPTIVO

TIPO DE PERSONA Y RELACION EDAD / SEXO

LESIONES A PEATONES POR SEXO Y EDAD



ANALISIS Y HALLAZGOS

ANÁLISIS DESCRIPTIVO

NIVELES DE LESIVIDAD

Nivel lesividad	Expedientes	%
Sin asistencia sanitaria	9908	80,9%
Asistencia sanitaria sólo en el lugar del accidente	4656	38,0%
Ingreso inferior o igual a 24 horas	1661	13,6%
Atención en urgencias sin posterior ingreso	1195	9,8%
Asistencia sanitaria inmediata en centro de salud o mutua	1009	8,2%
Ingreso superior a 24 horas	526	4,3%
Asistencia sanitaria ambulatoria con posterioridad	474	3,9%
Fallecido 24 horas	28	0,2%


44 %

Con asistencia sanitaria

ANALISIS Y HALLAZGOS

ANÁLISIS DESCRIPTIVO

CLIMA, FRANJA HORARIA




SINIESTROS CON POSITIVOS EN ALCOHOL O DROGAS




ANÁLISIS Y HALLAZGOS

ANÁLISIS PREDICTIVO

CLUSTERING POR ZONA GEOGRAFICA / K MEANS



Distribución de clusters por zona geográfica Suroeste



Tomamos de referencia la partición de las zonas geográficas en suroeste y noreste. El gráfico muestra que cuantos más grupos se crean con el **modelo K-Means**, más se ajustan los datos, pero llega un punto en que añadir más grupos ya no mejora mucho el resultado. Tras probar varias cantidades de clusters diferentes, se concluye que **el modelo encontró patrones, pero los grupos no están muy definidos** (silhouette score: 0.18), lo que indica que **las diferencias entre zonas no son tan claras**.

ANÁLISIS Y HALLAZGOS

ANÁLISIS PREDICTIVO

Objetivo: Explorar relaciones entre 10 variables categóricas y reducir dimensionalidad sin perder información clave.

Método: MCA genera componentes que resumen patrones de asociación entre categorías.

Resultado: Los **primeros 7 componentes** explican ≈ 74.6 inercia acumulada total (variabilidad).

Se decide **eliminar columnas menos relevantes** que no aportan significativamente a estos componentes.

¿Qué logramos con esto?

- **Claridad analítica:** Reduce ruido y redundancia en los datos.
- **Optimización para modelos:** Facilita el entrenamiento de algoritmos al eliminar variables poco informativas.

SCRIPT

cluster



Documento
Adobe Acrobat

MCA y modelos



Documento
Adobe Acrobat


ANÁLISIS Y HALLAZGOS

ANÁLISIS PREDICTIVO

CLASIFICACIÓN BINARIA: ¿HUBO ASISTENCIA MÉDICA? RANDOM FOREST

Las variables más relevantes para predecir la asistencia médica fueron el **tipo de vehículo, el tipo de accidente y el sexo**. Esto sugiere que ciertos perfiles están más asociados con la atención sanitaria tras un accidente.

El modelo acierta en casi el **75 % de los casos (accuracy: 0.7495)**, identificando bien la asistencia sanitaria. Tiene más dificultad con los casos sin asistencia, posiblemente por la redistribución proporcional de registros “Se desconoce” ante la falta de datos precisos.



ANÁLISIS Y HALLAZGOS

ANÁLISIS PREDICTIVO


CALASIFICACIÓN MULTICLASE: ¿QUÉ TIPO DE ACCIDENTE FUE? DECISION TREE

El modelo de árbol de decisión muestra un rendimiento sólido en la clasificación del tipo de accidente, con un **acierto del 89 %**, especialmente en **colisiones**, que son la clase objetivo principal.

La **curva ROC** alcanza un **AUC de 0.67**, lo que refleja una capacidad moderada para distinguir entre categorías. Aunque no es óptimo, el modelo **logra captar patrones relevantes** que permiten diferenciar tipos de accidente con eficacia razonable.

Clase	Precision	Recall	F1-score	Support
False	0.94	0.61	0.74	2106
True	0.88	0.99	0.93	6095
Accuracy			0.89	8201

CURVA DE ROC



CONCLUSIONES

- ✓ **Puente de Vallecas** lidera en número de expedientes, aunque poco menos de la mitad requieren asistencia médica. El distrito con menos accidentes es **Vicálvaro** aunque en asistencia médica está en el mismo rango que Puente de Vallecas. En la **zona Centro**, los atropellos son especialmente frecuentes y graves: más del 10% de los siniestros, y en el 86% de los casos se necesita atención sanitaria. Los vehículos sin motor, como bicicletas y patinetes, ya representan un 14,7% de los accidentes. El tipo de accidente mas habitual es la **colisión entre vehículos o furgonetas**.
- ✓ Octubre es el mes con mayor siniestralidad y agosto el más tranquilo, aunque dependiendo de la zona hay algunos otros meses con cierto repunte. Los implicados suelen ser hombres de entre 30 y 60 años, principalmente conductores. En los atropellos, destaca la mujer peatón como perfil recurrente.
- ✓ Ni el clima adverso ni la noche parecen influir. El consumo de alcohol o drogas es residual. Todo apunta a que los accidentes ocurren en desplazamientos laborales o cotidianos, no recreativos.

DASHBOARD

PAG. I

LINK



pfb.pbix



Documento
Adobe Acrobat

SINIESTRALIDAD COMUNIDAD DE MADRID 2024



20.690

Expedientes

44 %

Con asistencia sanitaria


Franja horaria

Todas


Distritos con más de 1.200 accidentes




Expedientes por distrito




Tipo de accidente



Expedientes al mes



Tipo de vehículo



DASHBOARD

PÁG. 2

SINIESTRALIDAD COMUNIDAD DE MADRID 2024



Distrito

Todas


97,09 %

Sin consumo de alcohol

99,59 %

Sin consumo de drogas


Sexo por rango de edades




Nivel lesividad

Nivel lesividad	Expedientes	%
Asistencia sanitaria ambulatoria con posterioridad	474	3,9%
Asistencia sanitaria inmediata en centro de salud o mutua	1009	8,2%
Asistencia sanitaria sólo en el lugar del accidente	4656	38,0%
Atención en urgencias sin posterior ingreso	1195	9,8%
Fallecido 24 horas	28	0,2%
Ingreso inferior o igual a 24 horas	1661	13,6%
Ingreso superior a 24 horas	526	4,3%
Sin asistencia sanitaria	9908	80,9%


Tipo de persona



Clima



Franja horaria





GRACIAS